

Matriz de consistencia preliminar

Jesus Campos Marco Barrera

Proyecto de Investigacion 2

Proyecto: Sistema de autenticacion multipartes de carteras Chanel mediante aprendizaje profundo.

Problema de investigacion. La autenticacion visual de carteras de lujo en mercados secundarios depende en gran medida de inspeccion experta. Esta dependencia dificulta una verificacion rapida, reproducible y escalable, especialmente cuando las falsificaciones imitan detalles locales como logotipos, herrajes y turnlocks.

Pregunta de investigacion. ¿En que medida un sistema de vision por computadora que combina imagenes generales de la cartera y componentes especificos como logo y turnlock permite identificar carteras Chanel genuinas y falsas?

Objetivo general. Desarrollar y evaluar un sistema de autenticacion automatica de carteras Chanel mediante modelos de aprendizaje profundo aplicados a imagenes generales y a componentes especificos del producto.

Hipotesis general. Un sistema multipartes basado en transferencia de aprendizaje y deteccion de componentes visuales permite diferenciar carteras genuinas y falsas con desempeno suficiente para apoyar la revision visual especializada.

Cuadro 1: Matriz de consistencia preliminar del proyecto.

Problema / pregunta	Objetivo especifico	Hipotesis especifica	Variable independiente	Variable dependiente	Variables de control	Operacionalizacion: indicadores, escala e instrumento
¿Puede un modelo clasificar la autenticidad usando imagenes generales de carteras sin mezclar fotografias del mismo grupo entre particiones?	Evaluar un modelo general de autenticacion sobre imagenes completas de carteras, usando una division por grupos.	H1: El modelo general EfficientNetB0 alcanza un desempeno de prueba aceptable para la autenticacion visual, con accuracy y F1 macro cercanos o superiores a 0.80.	Pipeline de clasificacion general con EfficientNetB0 y transferencia de aprendizaje.	Accuracy, precision, recall, F1-score y matriz de confusion en prueba.	Mismo dataset <code>chanel.zip</code> ; particion grupal 70/15/15; entrada 224×224; preprocesamiento EfficientNet; metrica de evaluacion constante.	Indicadores calculados con <code>model.evaluate</code> y <code>classification_report</code> sobre el conjunto de prueba. Escala: valores continuos entre 0 y 1 para metricas; conteos para matriz de confusion. Instrumento: notebook de entrenamiento y evaluacion.
¿Que arquitectura de transferencia de aprendizaje funciona mejor para clasificar partes genuinas y falsas?	Comparar EfficientNetB3, MobileNetV3Large y ResNet50 en el dataset de partes Chanel Boy y 2.55.	H2: ResNet50 obtiene mayor accuracy de validacion y menor loss que EfficientNetB3 y MobileNetV3Large bajo la misma particion experimental.	Tipo de arquitectura CNN: EfficientNetB3, MobileNetV3Large o ResNet50.	Accuracy de validacion, loss de validacion, F1 macro y F1 por clase.	Mismo dataset <code>Chanel_Parts.zip v08</code> ; misma division 80/20; semilla 123; 20 epocas; batch 16; pesos de clase; aumento horizontal; clasificador sigmoide; entrada 300×300 para EfficientNetB3 y 224×224 para MobileNetV3Large/ResNet50.	Indicadores obtenidos con <code>model.evaluate</code> y <code>classification_report</code> sobre el conjunto de validacion. Escala: accuracy/F1 entre 0 y 1; loss positiva continua. Instrumentos: historiales de entrenamiento, CSV <code>resumen_clasificacion_v08.csv</code> y <code>reporte_clasificacion_v08.csv</code> .

Problema / pregunta	Objetivo específico	Hipotesis específica	Variable independiente	Variable dependiente	Variables de control	Operacionalizacion: indicadores, escala e instrumento
¿Es posible localizar componentes diagnosticos y ajustar un umbral de decision para apoyar la autenticacion multipartes?	Detectar logo y turnlock con YOLOv8s y analizar umbrales exploratorios para la decision de autenticidad.	H3: YOLOv8s logra un mAP@0.5 alto para detectar componentes, y los umbrales exploratorios v08 permiten mejorar el equilibrio entre precision, recall y F1 frente a versiones anteriores.	Modelo de deteccion YOLOv8s y umbral de decision por clasificador.	Precision, recall, mAP@0.5, mAP@0.5:0.95, accuracy, F1 y umbral seleccionado.	Mismo dataset YOLO DATASET.zip; clases logo y turnlock; entrada 640×640; particiones train/val definidas; misma grilla de umbrales 0.50 a 0.95; 5 folds sobre probabilidades de validacion.	Indicadores de YOLO calculados por Ultralytics sobre validacion. Indicadores de umbral calculados por fold. Escala: metricas entre 0 y 1 o porcentaje; umbral entre 0 y 1. Instrumentos: CSV <code>resumen_yolo.csv</code> , <code>resultados_kfold_v08.csv</code> y <code>resumen_kfold_v08.csv</code> .

Plan de generalizacion fuera de la muestra

Plan principal: mini-holdout externo. Recolectar entre 50 y 200 imagenes nuevas de carteras Chanel desde fuentes no usadas en el entrenamiento, idealmente posteriores a la recoleccion original y provenientes de vendedores, paginas o contextos distintos. El pipeline, los pesos del modelo, el preprocesamiento y el umbral multipartes deben congelarse antes de evaluar este conjunto.

Reporte minimo. Comparar resultados internos contra externos: accuracy, balanced accuracy, precision, recall, F1 por clase, matriz de confusion, curvas precision-recall o ROC, calibracion/Brier si se usan probabilidades, y metricas YOLO por clase. Reportar tambien el cambio de distribucion: proporcion fake/genuine, proporcion por modelo de cartera, resolucion de imagen, brillo, blur y disponibilidad de logo/turnlock.

Plan B si no se consigue externo. Aplicar splits robustos: dejar grupos completos fuera, separar por modelo de cartera, separar por fuente de imagen si esa metadata esta disponible y evaluar robustez sintetica con perturbaciones de vision como cambios de iluminacion, desenfoque, compresion y oclusion parcial de componentes. El entregable seria una tabla por split o perturbacion y una figura de degradacion de metricas segun intensidad.