

Matriz de consistencia preliminar

Jesus Campos Marco Barrera

Proyecto de Investigacion 2

Proyecto: Sistema de autenticacion visual de carteras Chanel mediante deteccion de componentes y transferencia de aprendizaje.

Problema de investigacion. La autenticacion visual de carteras Chanel requiere evaluar detalles pequenos del producto, especialmente componentes como **logo** y **turnlock**. La revision manual de estas partes depende de experiencia especializada y puede variar entre evaluadores. Por ello, se propone un pipeline de vision por computadora donde YOLOv8s apoya el modelo de autenticacion al localizar los componentes relevantes, y luego modelos de transferencia de aprendizaje clasifican las imagenes de partes como **fake** o **genuine**.

Pregunta de investigacion. ¿En que medida un pipeline que usa YOLOv8s para localizar componentes y modelos CNN para clasificar partes permite distinguir imagenes **fake** y **genuine** de carteras Chanel?

Objetivo general. Desarrollar y evaluar un pipeline de autenticacion visual de partes de carteras Chanel, usando YOLOv8s para la deteccion de **logo** y **turnlock**, y modelos CNN preentrenados para clasificar las partes como **fake** o **genuine**.

Hipotesis general. El pipeline propuesto permite autenticar partes de carteras Chanel con una exactitud de validacion mayor o igual a 0.93 en el mejor clasificador y un F1 promedio mayor o igual a 0.93 en el analisis de umbrales.

Cuadro 1: Matriz de consistencia preliminar.

Problema / pregunta	Objetivo especifico	Hipotesis especifica	Variable independiente	Variable dependiente	Variables de control	Operacionalizacion: indicadores, escala e instrumento
¿Con que desempeno YOLOv8s localiza los componentes logo y turnlock que apoyan la autenticacion visual?	Medir el desempeno de YOLOv8s en la deteccion de logo y turnlock sobre el conjunto de validacion.	H1: YOLOv8s alcanza precision ≥ 0.95 , recall ≥ 0.83 , mAP@0.5 ≥ 0.88 y mAP@0.5:0.95 ≥ 0.65 en validacion.	Uso de YOLOv8s como detector de componentes.	Precision, recall, mAP@0.5 y mAP@0.5:0.95.	Dataset YOLO DATASET; clases logo y turnlock ; particion train/val definida; entrada 640×640; mismos parametros de entrenamiento y validacion.	Ultralytics calcula las metricas sobre 108 imagenes de validacion con 110 instancias. Escala: valores entre 0 y 1. Valores obtenidos: precision=0.9544, recall=0.8332, mAP@0.5=0.8879, mAP@0.5:0.95=0.6589.
¿Cual de las arquitecturas CNN clasifica mejor las partes Chanel como fake o genuine ?	Comparar EfficientNetB3, MobileNetV3Large y ResNet50 mediante accuracy, loss y F1 sobre el mismo conjunto de validacion.	H2: ResNet50 obtiene accuracy ≥ 0.93 , loss ≤ 0.22 y F1 macro ≥ 0.88 , superando a EfficientNetB3 y MobileNetV3Large en accuracy final.	Arquitectura CNN: EfficientNetB3, MobileNetV3Large o ResNet50.	Accuracy de validacion, loss de validacion, precision, recall, F1 por clase, macro F1 y matriz de confusion.	Dataset Chanel_Parts; 2446 imagenes; clases fake y genuine ; split 80/20 con semilla 123; 1957 imagenes de entrenamiento y 489 de validacion; batch 16; 20 epocas; class weights; RandomFlip horizontal; salida sigmoide.	model.evaluate y classification_report calculan las metricas. Escala: accuracy/F1 entre 0 y 1; loss positiva continua. Resultados: ResNet50 accuracy=0.9325, loss=0.2191, macro F1=0.88; MobileNetV3Large accuracy=0.9121, loss=0.2704, macro F1=0.86; EfficientNetB3 accuracy=0.8834, loss=0.3435, macro F1=0.81.

Problema / pregunta	Objetivo especifico	Hipotesis especifica	Variable independiente	Variable dependiente	Variables de control	Operacionalizacion: indicadores, escala e instrumento
¿Que umbral de decision produce mejor equilibrio entre precision, recall y F1 para la autenticacion de partes?	Evaluar umbrales entre 0.50 y 0.95 mediante StratifiedKFold de 5 folds sobre las probabilidades de validacion.	H3: Al menos un clasificador alcanza F1 promedio ≥ 0.93 en el analisis de umbrales; MobileNetV3Large y ResNet50 cumplen este criterio.	Umbral de decision aplicado a la probabilidad de clase genuine .	Accuracy promedio, precision promedio, recall promedio, F1 promedio y umbral medio.	Mismas probabilidades de validacion; grilla de umbrales 0.50 a 0.95 con paso 0.01; StratifiedKFold con 5 folds, shuffle=True y random_state=42 ; criterio de seleccion: 90 % precision y 10 % recall.	accuracy_score , precision_score , recall_score y f1_score calculan las metricas por fold. Escala: metricas entre 0 y 1; umbral entre 0 y 1. Resultados promedio: MobileNetV3Large F1=0.9338 y umbral medio=0.536; ResNet50 F1=0.9337 y umbral medio=0.636; EfficientNetB3 F1=0.8502 y umbral medio=0.652.

Variables principales

Tipo	Variable	Definicion conceptual	Definicion operacional
Independiente	Detector de componentes	Modelo que ubica regiones visuales usadas como apoyo para la autenticacion.	YOLOv8s evaluado en DATASET para detectar logo y turnlock .
Independiente	Arquitectura de clasificacion	Backbone CNN usado para extraer características visuales y clasificar autenticidad.	EfficientNetB3 con entrada 300×300; MobileNetV3Large y ResNet50 con entrada 224×224; pesos ImageNet; base congelada; salida sigmoide.
Independiente	Umbral de decision	Punto de corte que transforma la probabilidad del clasificador en etiqueta final.	Umbrales de 0.50 a 0.95 evaluados sobre probabilidades de validacion.
Dependiente	Desempeno de deteccion	Capacidad de YOLOv8s para detectar logo y turnlock .	Precision, recall, mAP@0.5 y mAP@0.5:0.95 en validacion.
Dependiente	Desempeno de clasificacion	Capacidad del clasificador para distinguir fake y genuine .	Accuracy, loss, precision, recall, F1 por clase, macro F1 y matriz de confusion.
Control	Dataset y particion	Condiciones constantes para comparar modelos.	Chanel_Parts , semilla 123, split 80/20, batch 16, 20 epocas, class weights y mismo conjunto de validacion.

Plan de generalizacion fuera de la muestra

Plan principal: mini-holdout externo. Recolectar entre 50 y 200 imagenes nuevas de carteras Chanel de fuentes no usadas en el entrenamiento. El pipeline debe mantenerse congelado: YOLOv8s localiza **logo** y **turnlock**, y el clasificador seleccionado predice **fake** o **genuine**.

Reporte minimo. Comparar la validacion interna contra el holdout externo usando accuracy, precision, recall, F1 por clase y matriz de confusion. Para YOLOv8s, reportar precision, recall, mAP@0.5 y mAP@0.5:0.95 por clase. Tambien registrar proporcion **fake/genuine**, cantidad de **logo/turnlock**, modelo de cartera, resolucion, iluminacion, blur y oclusiones.

Plan B si no se consigue externo. Aplicar splits robustos dentro de **Chanel_Parts**: separar por modelo de cartera (Boy vs 2.55) y evaluar perturbaciones sinteticas como cambios de iluminacion, desenfoque, compresion y oclusion parcial de **logo** o **turnlock**.