Proyecto:

SISTEMA DE AUTENTICACIÓN MULTIPARTE DE CARTERAS DE LUJO MEDIANTE APRENDIZAJE PROFUNDO Y ANÁLISIS DE IMÁGENES DIGITALES CAPTURADAS CON TELÉFONOS

Equipo / Integrantes:

- Marco Barrera Ninamango
- Jesus Campos Cardenas

Fecha de entrega:

[26/12/2025]

1. Resumen Ejecutivo

El presente sprint tuvo como objetivo desarrollar un prototipo funcional inicial para la autenticación automática de carteras de lujo utilizando imágenes capturadas mediante teléfonos celulares en condiciones reales de uso, sin control estricto de iluminación, ángulo o fondo.

Para ello, se implementó un pipeline básico de procesamiento de imágenes, un análisis exploratorio de datos (EDA) y un modelo baseline de clasificación binaria.

2. Sprint Planning

2.1 Objetivo del Sprint

Construir un pipeline mínimo viable que permita la ingesta, limpieza, exploración y entrenamiento de un modelo base sobre imágenes de carteras de lujo, con el fin de evaluar la factibilidad del enfoque basado en visión por computadora.

2.2 Historias de Usuario / Tareas Prioritarias

ID	Historia / Tarea	Responsable	Estado
1	Definir estructura del dataset de imágenes	Marco	Hecho
2	Implementar pipeline de ingesta y normalización	Marco - Jesus	Hecho
3	Realizar análisis exploratorio de datos (EDA)	Marco	Hecho
4	Implementar modelo baseline	Marco - Jesus	Hecho
5	Evaluar métricas iniciales del modelo	Marco	Hecho
6	Preparar demo técnica interna	Jesus	Hecho

3. Data Pipeline Básico

3.1 Descripción

Fuentes de datos:

El dataset está compuesto por carteras de lujo clasificadas en dos clases: genuinas y falsificadas. De acuerdo con las salidas del notebook, se identifican dos niveles de conteo: carteras únicas e imágenes totales.

Cada cartera puede estar representada por una o más imágenes, lo que explica que el número total de imágenes sea mayor al número de carteras.

La partición se realiza a nivel de carpetas de carteras (bag_id), no a nivel de imágenes. Se aplica 70% train, 15% validación, 15% test, con semilla aleatoria 42.

Sub-categoría	Total carteras	Train	Val	Test
bag---2.55	357	249	53	55
bag---boy	299	209	44	46
bag---gabrielle	242	169	36	37
bag---timeless	340	237	51	52

El dataset personalizado recorre todas las imágenes dentro de cada carpeta de cartera (bag_id) y construye una lista de muestras. El cuaderno reporta el conteo total de imágenes por split:

Split	Imágenes encontradas
Train	7408
Val	1638
Test	1551

3.2. Pipeline de Procesamiento de Datos

El pipeline implementado en el notebook incluye:

- Carga de imágenes desde carpetas organizadas por clase.
- Conversión de imágenes a formato RGB.
- Redimensionamiento a un tamaño uniforme.
- Normalización de valores de píxeles.

Este pipeline permite asegurar consistencia en los datos antes del entrenamiento del modelo.

4. EDA – Análisis Exploratorio de Datos

4.1 Objetivo del EDA

Confirmación que los datos utilizados sean consistentes y adecuados para el entrenamiento del modelo, así como identificar factores que puedan afectar el desempeño del modelo.

4.2 Hallazgos Principales

Se realiza un EDA orientado a validar la consistencia del dataset y del pipeline, incluyendo:

1. Verificación de la estructura (bags y número de carteras por modelo),
2. Conteo de imágenes por split,
3. Definición explícita de transforms para train vs. val/test,
4. Análisis de distribuciones de distancias al centro y curvas de entrenamiento.

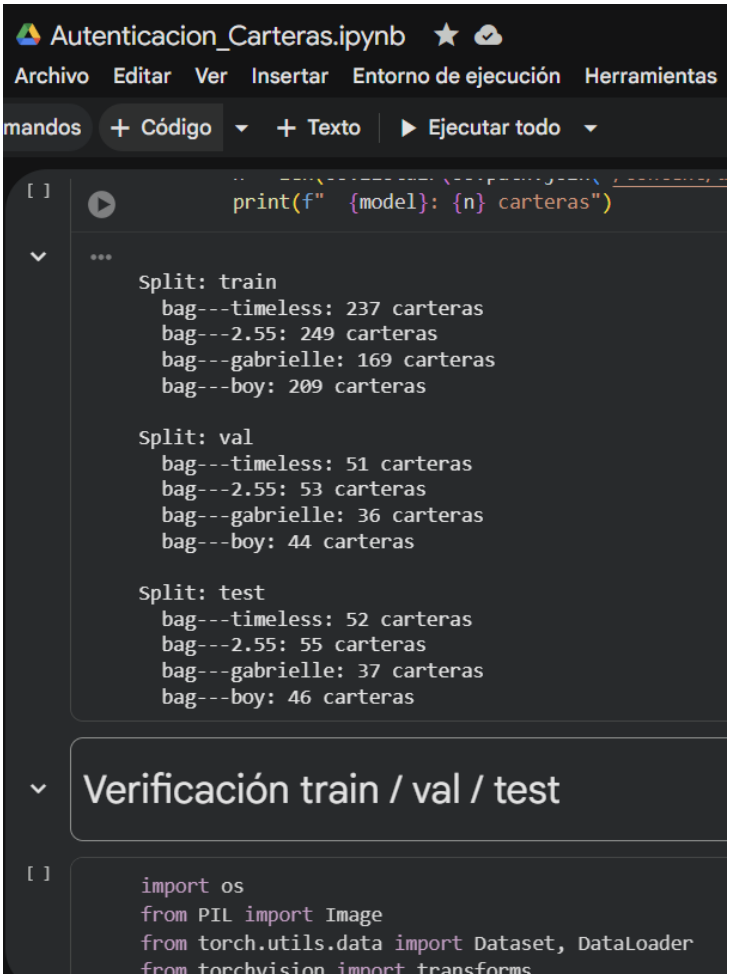

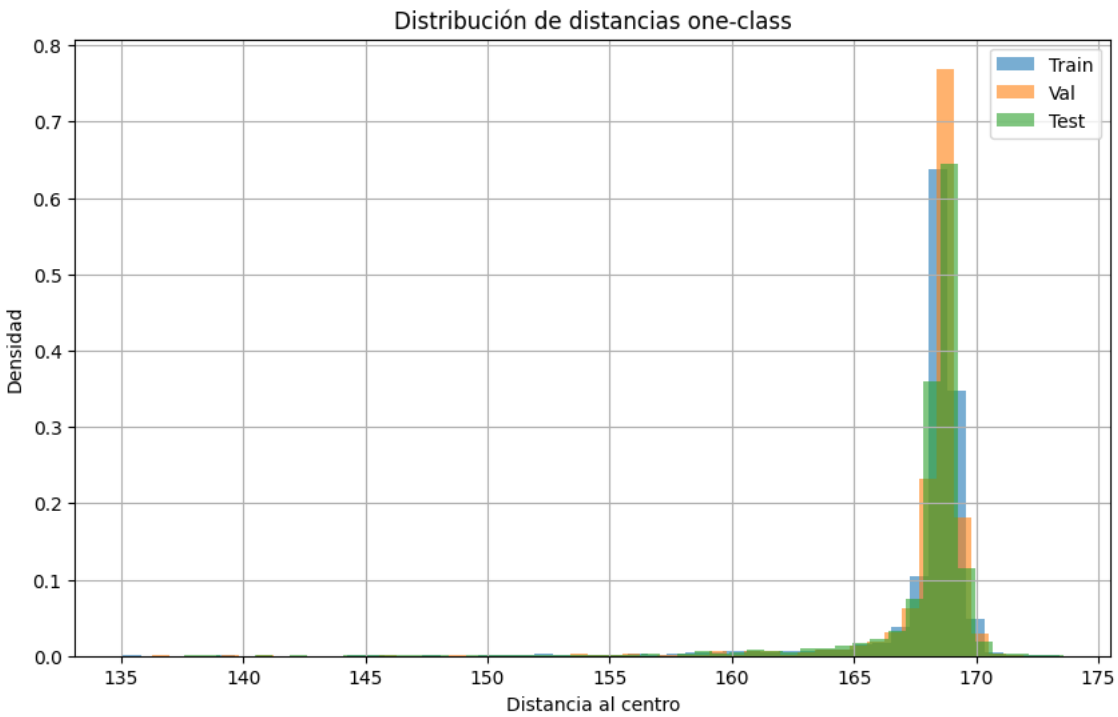

5. Modelo Baseline

5.1 Tipo de Modelo

EfficientNet-B0 preentrenada en ImageNet como backbone . Se elimina el clasificador original y se agrega una proyección a un embedding de 256 dimensiones (Linear + BatchNorm1d).

Se calcula un centro (promedio de embeddings) usando Train. Luego se entrena minimizando la distancia cuadrática al centro (OneClassLoss). Se entrena por 10 épocas con Adam.

Época	Train Loss	Val Loss
1	103.010644	240.324559
2	17.971865	85.488534
3	15.474652	87.943401
4	13.428602	37.638003
5	11.716333	63.605704
6	10.237180	59.991662
7	8.914426	67.075429
8	7.782543	143.832333
9	6.761659	151.844103
10	5.849321	168.158151

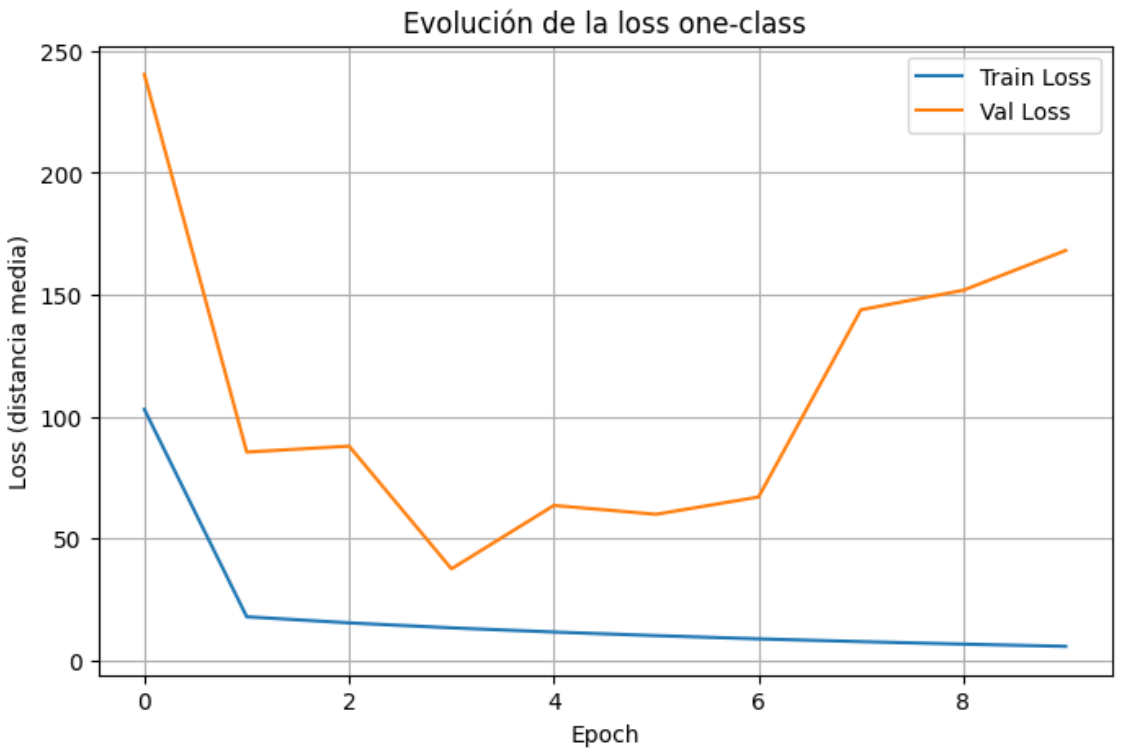

6. Pruebas Iniciales

6.1 Resultados del Modelo

Tras el entrenamiento, se calcula distancias al centro para cada imagen en train/val/test y muestra histogramas y estadísticas descriptivas.

Split	Mean	Std	Min	Max
Train	167.9439	2.8290	135.0316	173.4287
Val	168.1491	2.3870	136.2647	171.9375
Test	167.8527	3.2267	137.5974	173.5774

Se define un umbral a partir del percentil 97.5 de las distancias en validación.

- Percentil seleccionado: 97.5
- Umbral calculado: 169.76677

Split genuino	Rechazo (dist > umbral)
Train	0.0257829
Val	0.0250305
Test	0.0322373

6.2 Evaluación Individual

El cuaderno muestra un ejemplo de evaluación por cartera en una carpeta con 6 imágenes, calculando distancias por imagen y un score agregado.

Métricas	Valor
N imágenes	6
Mean	168.7528
P95	169.6418
Max	169.7078
Std	0.7278
Decisión	AUTÉNTICO

6.2 ROC

Se calcula ROC-AUC usando scores por cartera definidos como el máximo de distancias por imagen dentro de la cartera. Resultados reportados en el cuaderno:

- Total carteras evaluadas: 1048
- Genuinas: 184
- Fake_hard: 864

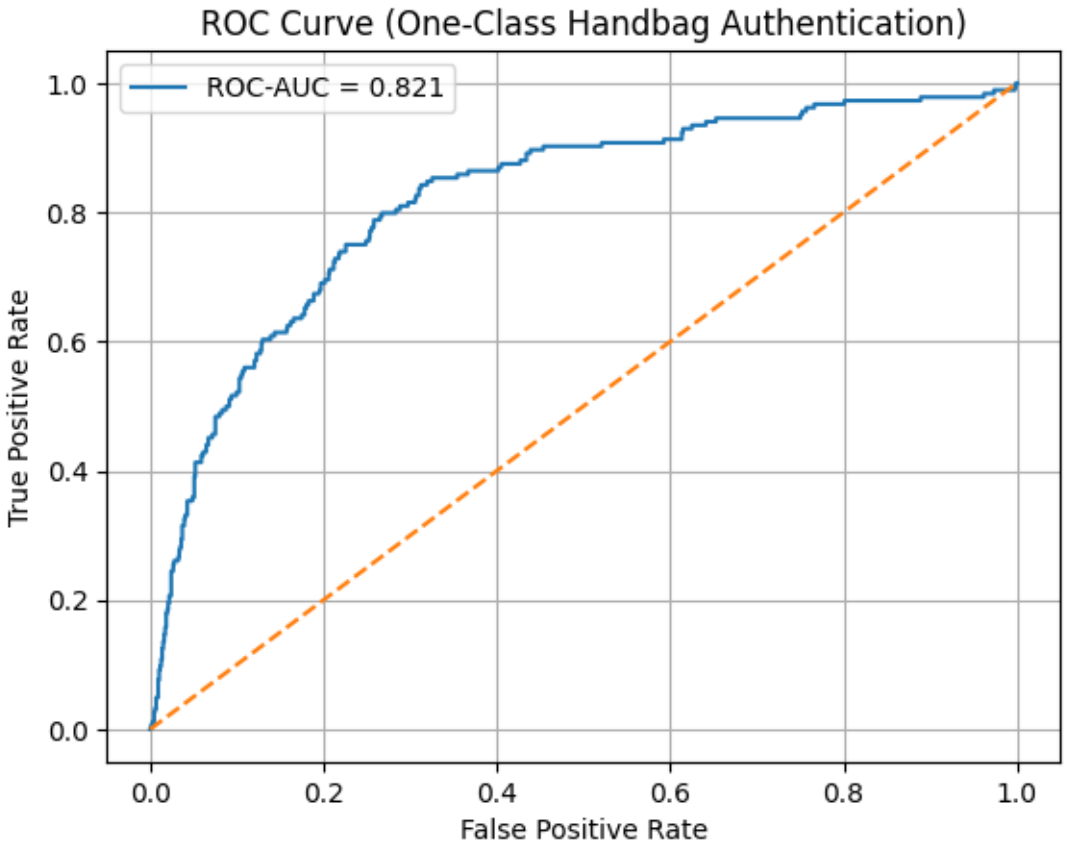

7. Avance de la Demo Interna

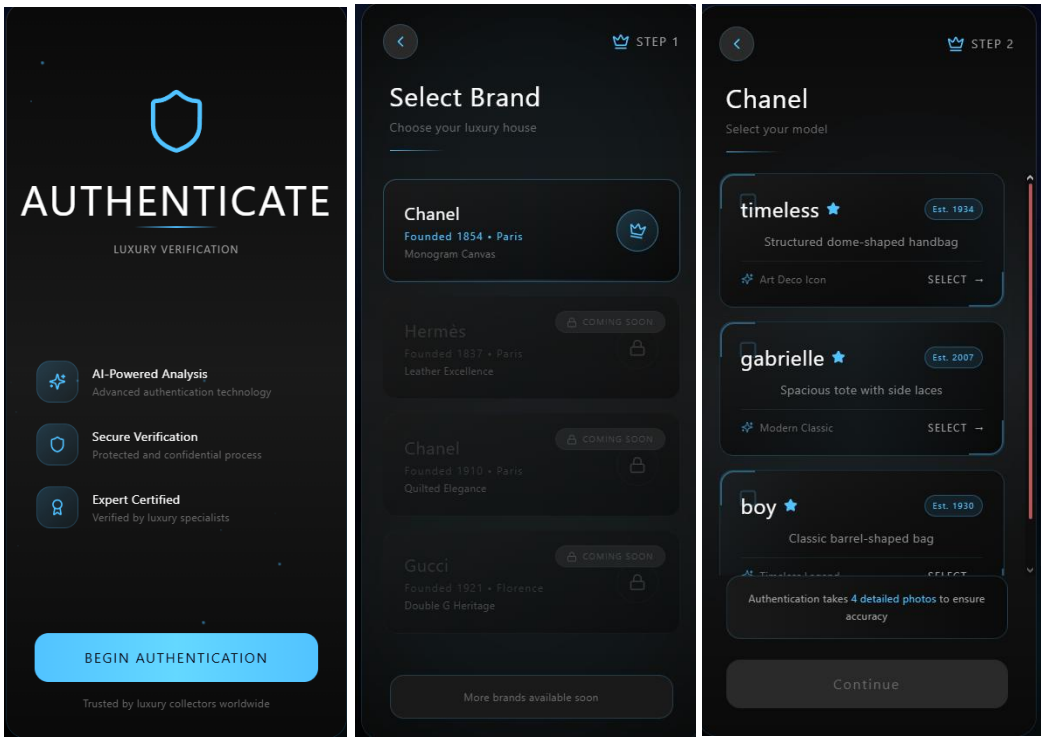

7.1 Qué se mostró

- Pipeline completo desde la carga de datos hasta la evaluación del modelo.
- Resultados del modelo baseline.
- Ejemplos visuales de predicciones correctas e incorrectas.

8. Conclusión

El enfoque one-class con embeddings de EfficientNet-B0 logra una separación razonable entre genuinos y fake_hard (ROC-AUC ~ 0.821). La loss de entrenamiento disminuye de forma sostenida; la loss de validación presenta variaciones (picos hacia las últimas épocas), lo que sugiere sensibilidad a la distribución de validación y/o a la variabilidad de las imágenes.