

PROYECTOS DE INVESTIGACIÓN II

Proyecto:

SISTEMA DE AUTENTICACIÓN MULTIPARTE DE CARTERAS DE LUJO MEDIANTE APRENDIZAJE PROFUNDO Y ANÁLISIS DE IMÁGENES DIGITALES CAPTURADAS CON TELÉFONOS

Equipo / Integrantes:

- Marco Barrera Ninamango
- Jesus Campos Cardenas

Fecha de entrega:

[26/12/2025]

1. Resumen Ejecutivo

El presente sprint tuvo como objetivo desarrollar un prototipo funcional inicial para la autenticación automática de carteras de lujo utilizando imágenes capturadas mediante teléfonos celulares en condiciones reales de uso, sin control estricto de iluminación, ángulo o fondo. Para ello, se implementó un pipeline básico de procesamiento de imágenes, un análisis exploratorio de datos (EDA) y un modelo baseline.

2. Sprint Planning

2.1 Objetivo del Sprint

Construir un pipeline mínimo viable que permita la ingesta, limpieza, exploración y entrenamiento de un modelo base sobre imágenes de carteras de lujo.

2.2 Historias de Usuario / Tareas Prioritarias

Nro.	Actividad	Responsable	Estado
1	Definir estructura del dataset	Marco	Hecho
2	Pipeline de ingesta y normalización	Marco - Jesus	Hecho
3	EDA	Marco	Hecho
4	Modelo baseline general	Marco - Jesus	Hecho
5	Evaluación del modelo baseline	Marco	Hecho
6	Desarrollo de modelo multi partes (logo y turnlock)	Marco - Jesus	Hecho

7	Entrenamiento y validación del modelo multi partes	Marco	Hecho
8	Generación de métricas y matriz de confusión	Marco	Hecho

3. Data Pipeline Básico

El dataset está compuesto por carteras clasificadas en dos clases: genuinas y falsificadas. Cada cartera puede tener múltiples imágenes. La partición se realiza por carpeta (bag_id) con 70% entrenamiento, 15% validación y 15% prueba. Conteo total de imágenes por split:

Genuino

Sub-categoría	Total carteras	Train	Val	Test
bag---2.55	357	249	53	55
bag---boy	299	209	44	46
bag---gabriele	242	169	36	37
bag---timeles	340	237	51	52

Split	Imágenes
Train	7408
Val	1638
Test	1551

Falsos

Sub-categoría	Total carteras	Train	Val	Test
bag---2.55	161	113	24	24
bag---boy	204	153	26	25
bag---gabriele	98	69	15	14

bag---timeles s	146	103	22	21
--------------------	-----	-----	----	----

Split	Imágenes
Train	3388
Val	724
Test	727

3.2 Pipeline de Procesamiento de Datos

El pipeline incluye carga de imágenes, conversión a RGB, redimensionamiento y normalización de píxeles.

4. EDA – Análisis Exploratorio de Datos

Se verifica la consistencia del dataset, conteo de imágenes y estructura de carpetas, además de análisis de distribuciones y curvas de entrenamiento.



5. Modelo Baseline

Se utiliza EfficientNetB0 preentrenada como backbone, eliminando la capa final y agregando una capa de clasificación con activación softmax para distinguir entre carteras Fake y Genuine. El modelo se entrena de forma supervisada utilizando las etiquetas del dataset, optimizando la función de pérdida de clasificación.

6. Pruebas Iniciales

Resultados:

	precision	recall	f1-score	support
Fake	0.65	0.98	0.78	750
Genuine	0.99	0.74	0.85	1517
accuracy			0.82	2267
macro avg	0.82	0.86	0.81	2267
weighted avg	0.88	0.82	0.83	2267



7. Conclusión Primer Modelo

El modelo de clasificación binaria logra un buen desempeño en la diferenciación entre carteras genuinas y falsas, alcanzando aproximadamente 82% de accuracy. Presenta alta El

modelo logra identificar ciertos patrones asociados a falsificaciones; sin embargo, todavía presenta confusiones entre las clases genuine y fake, especialmente debido al tamaño reducido y desbalanceado del dataset.


5. Modelo Baseline Multi Partes


Se implementó un modelo baseline utilizando imágenes de logo y turnlock de carteras Chanel 2.55 y Boy.

6. Pruebas Iniciales

Las pruebas iniciales permitieron validar el funcionamiento general del pipeline y evaluar el comportamiento del modelo frente a datos reales.

	precision	recall	f1-score	support
0	0.50	0.58	0.54	19
1	0.80	0.75	0.78	44
accuracy			0.70	63
macro avg	0.65	0.66	0.66	63
weighted avg	0.71	0.70	0.70	63





7. Conclusiones Modelo Multi Partes

El modelo baseline multi partes alcanzó aproximadamente 70% de accuracy en la clasificación entre componentes genuine y fake. Los resultados muestran mejor desempeño en la detección de componentes genuine, mientras que la clase fake aún presenta limitaciones debido al tamaño y desbalance del dataset.