

**UNIVERSIDAD NACIONAL DE INGENIERÍA**  
**[NOMBRE DE LA FACULTAD]**



TESIS

**Autenticación Automática de Carteras de Lujo mediante Deep  
Learning y Visión por Computadora**

Para optar el grado académico de Maestro en [NOMBRE DEL GRADO O MENCIÓN]

Elaborado por

[JESUS GIANPIERE CAMPOS CARDENAS]  
[MARCO ANTONIO BARRERA NINAMANGO]

Asesor

[MAYOR GRADO ACADÉMICO. NOMBRES Y APELLIDOS COMPLETOS]  
ORCID: [0000-0000-0000-0000]

LIMA - PERÚ  
2026

## ***Dedicatoria***

*[Sección opcional. Escriba la dedicatoria.]*

## **Agradecimientos**

*[Sección opcional. Mencione a las personas o instituciones que contribuyeron o apoyaron la realización del trabajo.]*

## Resumen

La investigación desarrolla y evalúa un prototipo de autenticación visual de carteras de lujo mediante deep learning y visión por computadora. El sistema localiza componentes relevantes —logo y mecanismo de cierre o turnlock— y clasifica la evidencia como genuina o falsificada. La evaluación considera macro-F1, detección de falsificaciones, consistencia entre segmentos, estabilidad ante variaciones de captura y tiempo de inferencia. YOLOv8s se emplea como módulo auxiliar de localización y se comparan MobileNetV3, EfficientNetB3 y ResNet50 mediante transferencia de aprendizaje. El alcance experimental se limita a carteras Chanel 2.55 y Chanel Boy. Los resultados preliminares muestran el mejor desempeño de validación para ResNet50, una menor sensibilidad en la clase falsificada, mejor detección del turnlock que del logo y degradación ante oscuridad y rotación. Por ello, la validación final requiere partición por cartera física, test independiente, evaluación end-to-end e intervalos de confianza. El estudio busca determinar en qué condiciones el prototipo funciona y dónde falla, sin atribuirle capacidad de certificación universal.

**Palabras clave:** autenticación visual; carteras de lujo; deep learning; visión por computadora; detección de falsificaciones.

## Abstract

This research develops and evaluates a visual authentication prototype for luxury handbags using deep learning and computer vision. The system localizes relevant components—the logo and the turnlock—and classifies the available evidence as genuine or counterfeit. Evaluation covers macro-F1, counterfeit detection, consistency across segments, stability under capture variations, and inference time. YOLOv8s is used as an auxiliary localization module, while transfer-learning classifiers based on MobileNetV3, EfficientNetB3, and ResNet50 are compared. The experimental scope is limited to Chanel 2.55 and Chanel Boy handbags. Preliminary results show the highest validation performance for ResNet50, lower sensitivity for the counterfeit class, better turnlock detection than logo detection, and degradation under darkness and rotation. Final validation therefore requires a handbag-level split, an independent test set, end-to-end evaluation, and confidence intervals. The study aims to establish the conditions under which the prototype works and fails, without claiming universal certification capability.

**Keywords:** visual authentication; luxury handbags; deep learning; computer vision; counterfeit detection.

## Tabla de Contenido

|                                                     |                                      |
|-----------------------------------------------------|--------------------------------------|
| <i>Dedicatoria</i> .....                            | i                                    |
| Agradecimientos .....                               | ii                                   |
| Resumen.....                                        | iii                                  |
| Abstract.....                                       | iv                                   |
| Lista de Tablas.....                                | ix                                   |
| Lista de Figuras.....                               | <b>¡Error! Marcador no definido.</b> |
| Introducción.....                                   | 1                                    |
| Capítulo I. Parte introductoria del trabajo .....   | 2                                    |
| 1.1 Generalidades .....                             | 2                                    |
| 1.2 Descripción del problema de investigación ..... | 2                                    |
| 1.3 Formulación del problema.....                   | 3                                    |
| 1.3.1 Problema general .....                        | 3                                    |
| 1.3.2 Problemas específicos .....                   | 3                                    |
| 1.4 Justificación .....                             | 4                                    |
| 1.4.1 Justificación práctica .....                  | 4                                    |
| 1.4.2 Justificación tecnológica.....                | 4                                    |
| 1.4.3 Justificación metodológica.....               | 4                                    |
| 1.5 Alcance y delimitación .....                    | 4                                    |
| 1.6 Objetivos.....                                  | 5                                    |
| 1.6.1 Objetivo general .....                        | 5                                    |
| 1.6.2 Objetivos específicos.....                    | 5                                    |
| 1.7 Hipótesis.....                                  | 6                                    |

|                                                                              |    |
|------------------------------------------------------------------------------|----|
| 1.7.1 Hipótesis general.....                                                 | 6  |
| 1.7.2 Hipótesis específicas.....                                             | 6  |
| 1.8 Estado del arte y antecedentes investigativos.....                       | 7  |
| 1.8.1 Evolución de la autenticación visual de productos.....                 | 7  |
| 1.8.2 Autenticación de carteras de lujo como clasificación visual fina ..... | 8  |
| 1.8.3 Análisis por partes y arquitecturas de dos etapas.....                 | 10 |
| 1.8.4 Aprendizaje de moda, atributos y representaciones regionales .....     | 11 |
| 1.8.5 Redes convolucionales y transferencia de aprendizaje .....             | 13 |
| 1.8.6 Detección de objetos y selección de evidencia.....                     | 14 |
| 1.8.7 Desbalance de clases y costos asimétricos.....                         | 15 |
| 1.8.8 Robustez ante condiciones de captura y cambio de dominio.....          | 16 |
| 1.8.9 Evaluación end-to-end, incertidumbre y desempeño operativo.....        | 17 |
| 1.8.10 Síntesis crítica y brecha de investigación .....                      | 18 |
| 1.9 Contribución esperada.....                                               | 20 |
| Capítulo II. Marcos teórico y conceptual.....                                | 21 |
| 2.1 Ejes teóricos .....                                                      | 21 |
| 2.2 Definiciones operativas.....                                             | 21 |
| Capítulo III. Desarrollo del trabajo de investigación .....                  | 23 |
| 3.1 Tipo y enfoque de investigación.....                                     | 23 |
| 3.2 Unidad de análisis .....                                                 | 23 |
| 3.3 Datos disponibles .....                                                  | 23 |
| 3.3.1 Dataset de detección.....                                              | 23 |
| 3.3.2 Dataset de clasificación.....                                          | 23 |

|                                                        |    |
|--------------------------------------------------------|----|
| 3.4 Pipeline de investigación .....                    | 24 |
| 3.5 Modelos .....                                      | 24 |
| Detector auxiliar .....                                | 24 |
| Clasificadores.....                                    | 24 |
| 3.6 Estrategia de partición .....                      | 25 |
| 3.7 Variables e indicadores.....                       | 25 |
| Variables de control.....                              | 25 |
| 3.8 Métricas principales .....                         | 26 |
| 3.9 Experimentos.....                                  | 26 |
| Experimento 1. Comparación de clasificadores.....      | 26 |
| Experimento 2. Evaluación por segmentos .....          | 26 |
| Experimento 3. Robustez .....                          | 27 |
| Experimento 4. Rendimiento operativo.....              | 27 |
| Experimento 5. Evaluación end-to-end.....              | 27 |
| 3.10 Criterios de aceptación .....                     | 27 |
| 3.11 Pruebas estadísticas.....                         | 28 |
| 3.12 Reproducibilidad .....                            | 28 |
| Capítulo IV. Análisis y discusión de resultados.....   | 30 |
| 4.1 Resultados preliminares de clasificación.....      | 30 |
| 4.2 Resultados preliminares por clase de ResNet50..... | 30 |
| 4.3 Resultados preliminares de detección .....         | 30 |
| 4.4 Resultados preliminares de robustez .....          | 31 |
| 4.5 Resultados preliminares de rendimiento .....       | 31 |



|                                                          |                                      |
|----------------------------------------------------------|--------------------------------------|
| 4.6 Validación pendiente antes de las conclusiones ..... | 31                                   |
| Conclusiones.....                                        | 33                                   |
| Recomendaciones.....                                     | 35                                   |
| Referencias bibliográficas .....                         | 36                                   |
| Anexos .....                                             | <b>¡Error! Marcador no definido.</b> |
| Anexo 1. Matriz de consistencia .....                    | <b>¡Error! Marcador no definido.</b> |

## Lista de Tablas

|                                                                  |                                      |
|------------------------------------------------------------------|--------------------------------------|
| Tabla 1. Síntesis de antecedentes y decisiones de la tesis ..... | 19                                   |
| Tabla 2. Distribución del dataset de detección .....             | 23                                   |
| Tabla 3. Distribución del dataset de clasificación .....         | 23                                   |
| Tabla 4. Variables e indicadores por hipótesis .....             | 25                                   |
| Tabla 5. Criterios de aceptación experimental.....               | 27                                   |
| Tabla 6. Resultados preliminares de clasificación .....          | 30                                   |
| Tabla 7. Resultados preliminares por clase de ResNet50 .....     | 30                                   |
| Tabla 8. Resultados preliminares de detección .....              | 30                                   |
| Tabla 9. Resultados preliminares de robustez.....                | 31                                   |
| Tabla 10. Resultados preliminares de rendimiento .....           | 31                                   |
| Tabla 11. Matriz de consistencia .....                           | <b>¡Error! Marcador no definido.</b> |

# Introducción

La autenticación visual de carteras de lujo es una tarea de clasificación fina en la que las diferencias entre un producto genuino y uno falsificado pueden concentrarse en componentes pequeños. La geometría del logo, las proporciones del mecanismo de cierre, la textura, el acabado y la relación espacial entre partes constituyen indicios potencialmente útiles. Al mismo tiempo, las fotografías disponibles en procesos de comercio electrónico y reventa presentan variaciones de iluminación, orientación, contraste, fondo, resolución y dispositivo de captura.

Esta investigación desarrolla y evalúa un prototipo que combina detección de objetos y clasificación de imágenes. YOLOv8s se utiliza para localizar el logo y el *turnlock*, mientras que MobileNetV3, EfficientNetB3 y ResNet50 se comparan como clasificadores de autenticidad. El dominio experimental se limita a carteras Chanel 2.55 y Chanel Boy y a una clasificación binaria entre genuina y falsificada.

El estudio no identifica el éxito del sistema únicamente con una exactitud elevada. La evaluación considera el macro-F1, el *recall* de la clase falsificada, la precisión de las decisiones genuinas, la tasa de aceptación de falsificaciones, la consistencia entre modelos y componentes, la robustez ante variaciones de captura y la latencia p95. Asimismo, se establece la separación de datos por cartera física para reducir la fuga de información entre fotografías del mismo producto.

El documento se organiza en cuatro capítulos. El Capítulo I presenta el problema, la justificación, el alcance, los objetivos, las hipótesis y el estado del arte. El Capítulo II expone los fundamentos teóricos y las definiciones operativas. El Capítulo III describe los datos, el pipeline, los modelos, las variables, las métricas y los experimentos. El Capítulo IV analiza los resultados preliminares y delimita las validaciones pendientes antes de emitir conclusiones definitivas.

# **Capítulo I. Parte introductoria del trabajo**

## **1.1 Generalidades**

La autenticación de una cartera de lujo a partir de imágenes digitales requiere identificar diferencias visuales que pueden encontrarse en zonas específicas del producto. Componentes como el logo y el mecanismo de cierre contienen detalles de forma, proporción, textura y acabado que pueden contribuir a diferenciar un producto genuino de uno falsificado.

El uso de fotografías permite plantear una alternativa no invasiva y accesible. Sin embargo, las imágenes pueden variar por iluminación, orientación, contraste, resolución, fondo y dispositivo de captura. Estas variaciones pueden afectar el desempeño de los modelos, incluso cuando la exactitud promedio parece alta.

La investigación se orienta a determinar si un sistema automático basado en detección de componentes y clasificación mediante deep learning puede producir decisiones reproducibles y medibles dentro del alcance definido.

## **1.2 Descripción del problema de investigación**

La autenticación visual automática no se resuelve únicamente entrenando un modelo y obteniendo una métrica promedio. Un sistema puede alcanzar una exactitud elevada y, al mismo tiempo, aceptar una proporción relevante de falsificaciones como genuinas, presentar menor desempeño en determinados modelos de cartera o degradarse ante condiciones de captura desfavorables.

La implementación experimental disponible evidencia cuatro dificultades:

1. El conjunto de clasificación está desbalanceado a favor de la clase genuina.
2. El desempeño de la clase falsificada es menor que el de la clase genuina.
3. La oscuridad, la rotación y el bajo contraste reducen el desempeño observado.

4. El detector y el clasificador han sido evaluados principalmente por separado, por lo que todavía debe verificarse el comportamiento del pipeline completo sobre productos no utilizados durante el desarrollo.

En consecuencia, el problema de investigación consiste en determinar si el sistema logra un desempeño superior al modelo de referencia, mantiene resultados consistentes en los segmentos relevantes y satisface un requerimiento operativo definido.

### **1.3 Formulación del problema**

#### ***1.3.1 Problema general***

**¿En qué medida un sistema automático basado en deep learning y análisis de componentes visuales permite autenticar carteras de lujo a partir de imágenes digitales, con un desempeño superior al modelo de referencia, estabilidad ante variaciones relevantes de captura y un tiempo de inferencia compatible con el proceso de uso definido?**

#### ***1.3.2 Problemas específicos***

1. **¿En qué medida el modelo de clasificación seleccionado supera al modelo de referencia en el desempeño de autenticación y en la reducción de falsificaciones aceptadas como genuinas?**
2. **¿En qué medida el desempeño del sistema se mantiene consistente entre los modelos Chanel 2.55 y Boy y entre los componentes logo y turnlock?**
3. **¿Cuánto se modifica el desempeño del sistema ante variaciones de iluminación, orientación y contraste representativas del proceso de captura?**
4. **¿La configuración optimizada de inferencia satisface el requerimiento de latencia y capacidad de procesamiento definido para el prototipo sin alterar sus predicciones?**

## **1.4 Justificación**

### **1.4.1 Justificación práctica**

La autenticación mediante imágenes puede apoyar procesos de revisión en comercio electrónico, reventa y evaluación preliminar de productos, sin requerir procedimientos invasivos. El prototipo busca proporcionar una estimación automática y reproducible dentro de un alcance controlado.

### **1.4.2 Justificación tecnológica**

La investigación integra detección de objetos, clasificación de imágenes, análisis por componentes y optimización de inferencia. El valor tecnológico no se limita a implementar modelos, sino a evaluar su comportamiento por clase, segmento y condición de captura.

### **1.4.3 Justificación metodológica**

El estudio adopta criterios cuantitativos que permiten aceptar o rechazar las hipótesis. Se priorizan macro-F1, desempeño de la clase falsificada, tasa de aceptación de falsificaciones, estabilidad por segmento y latencia p95, evitando expresiones imprecisas como “desempeño suficiente” sin un criterio definido.

## **1.5 Alcance y delimitación**

La investigación comprende:

- carteras Chanel de los modelos 2.55 y Boy;
- componentes visuales logo y turnlock;
- clasificación binaria entre genuina y falsificada;
- detección de componentes mediante YOLO;
- comparación de EfficientNetB3, MobileNetV3 y ResNet50;
- evaluación de iluminación, orientación y contraste;
- medición de latencia y throughput;

- desarrollo de un prototipo experimental.

La investigación no demuestra, dentro del alcance actual:

- generalización a todas las marcas de lujo;
- generalización a todos los modelos de cartera;
- análisis de costuras, etiquetas, texturas u otros componentes no incluidos;
- sustitución definitiva de un perito;
- certificación comercial de autenticidad;
- escalabilidad empresarial en producción;
- desempeño directo en teléfonos celulares sin una prueba específica en dichos dispositivos.

## **1.6 Objetivos**

### ***1.6.1 Objetivo general***

**Determinar si un sistema automático basado en deep learning y análisis de componentes visuales alcanza un desempeño de autenticación superior al modelo de referencia, mantiene estabilidad entre segmentos y condiciones relevantes de captura, y satisface el requerimiento operativo de inferencia definido para el prototipo.**

### ***1.6.2 Objetivos específicos***

- 1. Determinar si el modelo seleccionado supera al modelo de referencia en macro-F1, detección de falsificaciones y tasa de aceptación de falsificaciones sobre un conjunto de prueba independiente.**
- 2. Determinar si el desempeño de autenticación se mantiene consistente entre los modelos Chanel 2.55 y Boy y entre los componentes logo y turnlock.**
- 3. Determinar la estabilidad del desempeño ante variaciones de iluminación, orientación y contraste representativas de las imágenes de entrada.**

4. **Determinar si la inferencia optimizada cumple el umbral de latencia p95 y el throughput requeridos sin modificar el desempeño predictivo del modelo.**

## **1.7 Hipótesis**

### ***1.7.1 Hipótesis general***

**El sistema automático basado en deep learning y análisis de componentes visuales presenta un desempeño de autenticación superior al modelo de referencia y mantiene niveles de estabilidad y latencia compatibles con los criterios definidos para el prototipo.**

### ***1.7.2 Hipótesis específicas***

#### **H1. Desempeño frente al modelo de referencia**

El modelo seleccionado obtiene un macro-F1 superior y una tasa de aceptación de falsificaciones inferior a la del modelo de referencia sobre el mismo conjunto de prueba independiente.

#### **H2. Consistencia entre segmentos**

La diferencia de desempeño entre Chanel 2.55 y Chanel Boy, y entre logo y turnlock, no supera cinco puntos porcentuales en las métricas principales, siempre que cada segmento tenga un tamaño de evaluación suficiente.

#### **H3. Robustez ante variaciones de captura**

Las variaciones de iluminación, orientación y contraste no reducen el macro-F1 ni aumentan la tasa de aceptación de falsificaciones en más de cinco puntos porcentuales respecto de las imágenes originales.

#### **H4. Rendimiento operativo**

La configuración optimizada conserva las decisiones del modelo y alcanza una latencia p95 menor o igual a dos segundos en la evaluación end-to-end realizada sobre el entorno de ejecución documentado.



## **1.8 Estado del arte y antecedentes investigativos**

### ***1.8.1 Evolución de la autenticación visual de productos***

La autenticación de productos físicos ha sido abordada históricamente mediante marcas de seguridad, etiquetas, hologramas, códigos, identificadores de radiofrecuencia y mecanismos de trazabilidad. Estas alternativas pueden ser eficaces cuando el fabricante controla el ciclo de vida del producto, pero presentan limitaciones para artículos que ya circulan en mercados de reventa, para bienes que no incorporan identificadores verificables o para escenarios en los que el usuario solo dispone de fotografías. En ese contexto, la autenticación visual automática busca inferir la condición de autenticidad a partir de características observables del objeto, sin modificarlo y sin requerir necesariamente acceso a su cadena de suministro.

Un antecedente relevante es el sistema de Sharma et al. [1], que combinó microscopía de gran angular, dispositivos móviles y modelos de aprendizaje automático para distinguir materiales y productos genuinos de falsificados. El trabajo evaluó millones de imágenes microscópicas de cuero, tejidos, papel, plástico y otros objetos, y mostró que las regularidades de fabricación pueden convertirse en evidencia discriminativa. Su principal aporte consiste en formular la autenticación como reconocimiento visual de patrones materiales. Sin embargo, el uso de un accesorio de captura microscópica introduce una dependencia de hardware especializado que no siempre está disponible en un proceso de evaluación remota basado en fotografías convencionales.

La literatura más reciente ha explorado la posibilidad de operar con cámaras de teléfonos inteligentes y condiciones débilmente controladas. Garcia-Cotte et al. [7] desarrollaron un sistema de clasificación de productos genuinos y falsificados a partir de imágenes de marcas visuales capturadas en entornos reales. Además de comparar arquitecturas, incorporaron normalización geométrica y una opción de rechazo para casos de baja confianza. Este enfoque es importante porque reconoce que un sistema de autenticación no tiene que forzar una decisión en todas las entradas: puede abstenerse

cuando la evidencia visual es insuficiente. No obstante, sus resultados sobre prendas y emblemas no demuestran de forma automática un desempeño equivalente en carteras, cuyos indicios pueden depender de piezas metálicas, proporciones, grabados y acabados específicos.

Estos antecedentes permiten distinguir dos familias de soluciones. La primera utiliza instrumentación o señales diseñadas para autenticar; la segunda aprende directamente de imágenes del producto. La presente investigación pertenece a la segunda familia y adopta una restricción adicional: la decisión se apoya en fotografías corrientes y en componentes visibles de carteras Chanel 2.55 y Boy. Esta delimitación mejora la viabilidad del prototipo, pero exige controlar la iluminación, la orientación, el contraste, el encuadre y la resolución, porque estas variables pueden modificar la apariencia de los mismos detalles que sustentan la autenticación.

### ***1.8.2 Autenticación de carteras de lujo como clasificación visual fina***

La distinción entre una cartera genuina y una falsificada es un problema de clasificación fina. En una clasificación convencional, las diferencias entre categorías suelen ser amplias; por ejemplo, una cartera y un calzado poseen siluetas y estructuras claramente distintas. En la autenticación, ambas clases representan el mismo tipo de producto, la misma marca e incluso el mismo modelo. La diferencia puede concentrarse en la separación entre letras, la simetría de un logo, la geometría de un cierre, la profundidad de un grabado o el acabado de una superficie. En consecuencia, la variación dentro de una misma clase puede ser mayor que la separación visual entre clases: fotografías genuinas tomadas con cámaras y luces distintas pueden diferir considerablemente, mientras que una falsificación de alta calidad puede asemejarse mucho a un ejemplar genuino.

Peng et al. [2] trataron este problema mediante una red de atención híbrida y una función de pérdida guiada por tasadores. Su conjunto incluyó distintas marcas y partes de carteras, y su propuesta combinó atención espacial y de canal con una ponderación

mayor para la clase falsificada y para las imitaciones difíciles. El aporte metodológico es doble. Primero, la atención dirige el aprendizaje hacia regiones discriminativas en lugar de distribuirlo de manera uniforme. Segundo, la pérdida incorpora la asimetría del problema, pues confundir una falsificación convincente con un producto genuino puede ser más crítico que equivocarse en una muestra evidente. Esta idea respalda que la tesis reporte de forma explícita el *recall* de la clase falsificada y la tasa de falsificaciones aceptadas, y no solo la exactitud global.

En otra línea, Peng et al. [4] combinaron una red generativa con atención externa y clasificadores convolucionales para mejorar la representación de carteras genuinas y falsificadas. La propuesta buscó atender simultáneamente información local y global, además de mitigar el desbalance del conjunto. Aunque los métodos generativos pueden enriquecer la variabilidad disponible, su uso requiere cautela: las imágenes sintéticas deben representar transformaciones plausibles y no introducir artefactos que el clasificador aprenda como atajos. Por ello, la presente investigación prioriza aumentaciones controladas y una evaluación separada sobre imágenes reales no utilizadas durante el desarrollo.

Apipawinwongsa y Limpiyakorn [5] estudiaron imágenes de materiales de carteras mediante VGG16 y DenseNet121, complementadas con patrones binarios locales. La combinación entre características aprendidas y descriptores de textura sugiere que la autenticación no depende únicamente de la forma global; la microestructura visual de materiales y acabados también puede aportar evidencia. Sin embargo, su unidad de análisis se concentra en imágenes de material, mientras que esta tesis considera componentes funcionales y de marca —logo y *turnlock*— dentro de un pipeline que primero debe localizarlos.

En conjunto, estos trabajos confirman que la autenticación de carteras se beneficia de representaciones finas, atención a regiones, tratamiento del desbalance y conocimiento del dominio. También muestran que la comparación directa de valores de exactitud entre estudios es limitada: cambian las marcas, las partes fotografiadas, los

protocolos de partición, el tamaño de los conjuntos, la calidad de las etiquetas y la dificultad de las falsificaciones. En consecuencia, el estado del arte debe analizar no solo qué modelo obtiene una cifra mayor, sino bajo qué datos, unidad de análisis y condiciones se obtiene.

### **1.8.3 Análisis por partes y arquitecturas de dos etapas**

Una tendencia especialmente relacionada con esta tesis es dividir la autenticación en localización y clasificación. Peng et al. [3] propusieron un marco de dos etapas para imágenes de logos de carteras de lujo. En la primera etapa, detectaron puntos locales de identificación; en la segunda, combinaron información local y global para emitir la predicción de autenticidad. El estudio construyó un conjunto de 639 imágenes de logos y reportó ventajas frente a una CNN aplicada directamente sobre la imagen completa. Su conclusión metodológica es pertinente: cuando las señales relevantes ocupan una fracción pequeña de la fotografía, el recorte de regiones puede aumentar la proporción de información útil que recibe el clasificador.

El análisis por partes también aparece en sistemas que solicitan al usuario fotografías específicas de etiquetas, hebillas, texturas o códigos. Esta estrategia reduce la variabilidad de la escena y permite entrenar modelos especializados, pero transfiere al usuario la responsabilidad de encuadrar correctamente cada detalle. Un pipeline automático intenta reducir esa carga mediante un detector que localiza los componentes. Sin embargo, introduce una nueva fuente de error: si el detector omite el logo, recorta parcialmente el *turnlock* o selecciona una región incorrecta, el clasificador recibe evidencia degradada aunque su desempeño sobre recortes manuales sea alto.

Yang et al. [6] propusieron en 2024 una red ligera de aprendizaje multitarea guiada por áreas clave. El método alteró parches de regiones importantes para crear una tarea auxiliar y orientar la atención de la tarea principal. Además, utilizó detección de objetos para extraer etiquetas de cuero y piezas metálicas antes de la clasificación. El trabajo es relevante porque conecta tres necesidades habituales del dominio: datos

escasos, diferencias sutiles y extracción de componentes. También advierte que deformar una imagen al redimensionarla puede destruir diferencias pequeñas, motivo por el cual preservó la relación de aspecto mediante relleno antes del escalamiento.

La presente tesis adopta una lógica de dos etapas semejante, pero con una contribución evaluativa específica. YOLOv8s se utiliza como detector auxiliar de logo y *turnlock*; posteriormente, MobileNetV3, EfficientNetB3 y ResNet50 se comparan como clasificadores. La decisión final no debe evaluarse únicamente sobre recortes ideales. Se requiere una prueba end-to-end con imágenes completas y carteras no vistas, porque la sensibilidad total del sistema depende de la probabilidad conjunta de localizar evidencia válida, clasificarla correctamente y fusionar las predicciones disponibles.

Este punto diferencia tres niveles de desempeño que no deben confundirse. El primero es la calidad del detector, expresada mediante precisión, *recall* y mAP. El segundo es la calidad del clasificador sobre recortes válidos. El tercero es la calidad de la decisión por cartera cuando ambos módulos interactúan. Un detector con alta precisión pero *recall* insuficiente puede producir pocos recortes erróneos, pero omitir componentes decisivos. A su vez, un clasificador excelente no compensa una omisión sistemática. Por ello, la tesis reporta resultados modulares y reserva una evaluación final del pipeline completo.

#### **1.8.4 Aprendizaje de moda, atributos y representaciones regionales**

Los grandes conjuntos de moda no fueron creados específicamente para autenticar falsificaciones, pero aportaron metodologías para localizar prendas, partes, atributos y correspondencias entre imágenes. DeepFashion [8] reunió más de ochocientas mil imágenes con categorías, atributos, puntos de referencia y pares entre fotografías comerciales y de consumidores. El modelo FashionNet utilizó atributos y puntos de referencia para aprender una representación más robusta. Este antecedente demuestra que el conocimiento de la estructura de un artículo puede orientar el aprendizaje mejor que una etiqueta global aislada.

DeepFashion2 [9] amplió este enfoque con anotaciones de escala, punto de vista, oclusión, cajas, máscaras y puntos de referencia densos. Su valor para la presente investigación reside en la consideración explícita de variaciones que también aparecen en las fotografías de carteras: el objeto puede ocupar escalas distintas, verse parcialmente, cambiar de orientación o encontrarse en una escena de consumo en lugar de un catálogo. Aunque el dominio de DeepFashion2 se centra en prendas, su diseño de evaluación refuerza la necesidad de segmentar los resultados por condiciones y no asumir que una métrica promedio representa todos los casos.

Fashionpedia [10] integró segmentación de instancias y localización de atributos finos mediante una ontología creada con conocimiento experto. Este trabajo ofrece una lección conceptual para la autenticación: la evidencia no se limita a saber que una región corresponde a un logo o a un cierre; también interesa describir propiedades como forma, simetría, textura, disposición y relación entre partes. La tesis actual no implementa una ontología completa de atributos de Chanel, pero su análisis por componentes constituye un paso intermedio entre la clasificación global y una explicación estructurada por atributos.

Lang et al. [11] abordaron la recuperación de diseños de moda plagiados mediante representaciones regionales guiadas por puntos de referencia. Su propuesta partió de que una copia puede alterar solo una zona para evitar los métodos basados en similitud global. Aunque plagio de diseño y autenticidad no son tareas equivalentes, comparten una dificultad: una diferencia local pequeña puede ser decisiva mientras gran parte de la apariencia permanece igual. Esta coincidencia justifica comparar regiones y conservar información espacial en lugar de reducir toda la cartera a una única representación global.

La transferencia de estos avances al problema de autenticidad debe hacerse con cautela. Los atributos útiles para reconocer una categoría de prenda no necesariamente son los mismos que distinguen una falsificación. Un modelo preentrenado puede aportar filtros generales de bordes, textura y forma, pero requiere ajuste con ejemplos genuinos y

falsificados del dominio específico. Por esta razón, la investigación usa transferencia de aprendizaje como punto de partida y limita sus conclusiones a Chanel 2.55, Chanel Boy, logo y *turnlock*.

#### **1.8.5 Redes convolucionales y transferencia de aprendizaje**

ResNet introdujo conexiones residuales para facilitar la optimización de redes profundas [12]. En la autenticación visual, esta profundidad puede ayudar a combinar características de bajo nivel —bordes, brillo y textura— con configuraciones más abstractas —proporciones y organización de componentes—. ResNet50 se ha convertido además en una referencia frecuente en estudios de carteras, lo que permite contrastar los resultados del prototipo con antecedentes que utilizan un backbone conocido.

EfficientNet propuso escalar de forma coordinada profundidad, anchura y resolución [13]. Este principio resulta atractivo cuando las diferencias de autenticidad son pequeñas y una mayor resolución puede preservar detalles; sin embargo, incrementar la resolución también eleva el costo de inferencia. EfficientNetB3 se incluye en esta tesis para observar si su equilibrio entre capacidad y eficiencia ofrece ventajas en el conjunto disponible.

MobileNetV3 fue diseñado mediante búsqueda de arquitectura consciente del hardware y optimizaciones orientadas a dispositivos con recursos restringidos [14]. Su inclusión como baseline tiene sentido operativo: un sistema de autenticación podría desplegarse en un servicio de respuesta rápida o, con validación adicional, en un dispositivo móvil. No obstante, una arquitectura ligera no debe seleccionarse solo por velocidad; se debe verificar si conserva sensibilidad suficiente para la clase falsificada.

La comparación entre estas arquitecturas debe cumplir condiciones comunes de entrenamiento y evaluación. Es necesario usar la misma partición por cartera, el mismo preprocesamiento, una política documentada de aumentación y un procedimiento equivalente de selección de umbral. Si cada modelo se evalúa con muestras o umbrales

distintos, la diferencia puede atribuirse al protocolo y no a la arquitectura. Además, el test final debe permanecer bloqueado hasta fijar el modelo y el umbral.

La transferencia de aprendizaje es especialmente pertinente porque los conjuntos de autenticidad suelen ser mucho menores que los de clasificación general. Los pesos preentrenados reducen la necesidad de aprender desde cero representaciones básicas, pero no eliminan el riesgo de sobreajuste. El ajuste debe controlar la complejidad, observar las curvas de entrenamiento y validar sobre productos independientes. Una partición por imagen puede inflar el desempeño si fotografías casi idénticas de la misma cartera aparecen en entrenamiento y prueba; por ello, la unidad de partición adoptada es el producto físico.

#### **1.8.6 Detección de objetos y selección de evidencia**

YOLO formuló la detección como una predicción unificada de cajas y probabilidades mediante una sola red [15]. Su velocidad y su integración sencilla explican su uso extendido en pipelines que requieren localizar objetos antes de clasificarlos. En esta investigación, YOLOv8s no emite directamente la autenticidad; actúa como módulo de selección de evidencia para encontrar logo y *turnlock*.

Esta separación tiene ventajas interpretativas. Permite saber si un error se origina en la ausencia del componente, en un recorte deficiente o en la clasificación. También facilita analizar diferencias entre componentes. Los resultados preliminares muestran que el *turnlock* obtiene mejor mAP y *recall* que el logo, lo que sugiere que la disponibilidad de evidencia no es uniforme. Si el logo se omite con mayor frecuencia, la regla de fusión debe definir qué ocurre cuando solo existe una predicción válida.

La selección de evidencia también requiere control de calidad. No todos los recortes detectados son igualmente informativos: algunos pueden ser pequeños, borrosos, estar saturados o quedar parcialmente fuera de la imagen. Un sistema operativo debería registrar el tamaño relativo de la caja, la confianza del detector y



criterios básicos de calidad. Cuando la evidencia no supera esos controles, la salida más segura puede ser “no concluyente” en lugar de genuina o falsificada.

La literatura sobre arquitecturas de dos etapas respalda la localización de detalles, pero todavía deja abierta la forma óptima de fusionarlos. Una regla promedio supone que todos los componentes aportan evidencia comparable; una regla conservadora puede clasificar como falsificada si cualquiera de los componentes supera cierto umbral; una regla aprendida requiere datos suficientes a nivel de cartera. La tesis debe documentar la regla seleccionada, calibrarla únicamente con validación y evaluar la decisión final sin reajustar el test.

#### ***1.8.7 Desbalance de clases y costos asimétricos***

El conjunto de clasificación de la investigación contiene muchas más imágenes genuinas que falsificadas. Esta distribución refleja una dificultad común: los productos genuinos pueden documentarse sistemáticamente, mientras que las falsificaciones verificadas son más difíciles de obtener y cambian con el tiempo. Si se optimiza la exactitud sin correcciones, el modelo puede favorecer la clase mayoritaria y producir una cifra global alta a pesar de aceptar una fracción relevante de falsificaciones.

Cui et al. [16] propusieron ponderar las clases mediante el número efectivo de muestras, reconociendo que ejemplos adicionales de una clase abundante aportan información marginal decreciente. La literatura de reconocimiento de cola larga también ha mostrado que remuestreo, ponderación y aprendizaje métrico modifican de maneras distintas la frontera de decisión. En el dominio específico de carteras, la pérdida guiada por tasadores de Peng et al. [2] asignó mayor importancia a falsificaciones y casos de alta imitación. Estos antecedentes justifican evaluar pesos de clase o pérdidas sensibles al costo durante el entrenamiento.

Sin embargo, el tratamiento del desbalance no termina en la función de pérdida. El umbral de decisión determina el intercambio entre aceptar falsificaciones y rechazar productos genuinos. Un umbral de 0,5 no es necesariamente óptimo si las probabilidades

están descalibradas o si los costos de error son asimétricos. Guo et al. [19] mostraron que redes modernas pueden producir confianzas mal calibradas y que el escalamiento por temperatura puede mejorar la correspondencia entre probabilidad y frecuencia de acierto. Para la tesis, cualquier calibración debe aprenderse en validación y comprobarse sin modificar el test.

Las métricas principales deben reflejar ambos lados del problema. El macro-F1 otorga el mismo peso a las dos clases; el *recall* de falsificada mide cuántas falsificaciones se detectan; la precisión de la predicción genuina expresa cuántas decisiones genuinas son correctas; y la tasa de aceptación de falsificaciones representa directamente el error crítico. La matriz de confusión y los intervalos de confianza completan la interpretación, especialmente cuando la cantidad de falsificaciones del test es limitada.

#### **1.8.8 Robustez ante condiciones de captura y cambio de dominio**

Un modelo puede obtener buenos resultados en imágenes similares a las de entrenamiento y degradarse ante variaciones comunes. Hendrycks y Dietterich [17] sistematizaron la evaluación de robustez frente a corrupciones como ruido, desenfoque, cambios de contraste y otras alteraciones. Aunque sus benchmarks se construyeron sobre clasificación general, el principio es directamente aplicable: la robustez debe medirse con perturbaciones definidas y severidades controladas, no inferirse a partir de la exactitud original.

Geirhos et al. [18] describieron el aprendizaje de atajos como el uso de señales que funcionan en el conjunto habitual pero fallan cuando cambia el contexto. En una colección de carteras, posibles atajos incluyen el fondo de la fotografía, la resolución, una marca de agua, el tipo de dispositivo o patrones de edición asociados accidentalmente a una clase. Si las imágenes falsificadas provienen de fuentes distintas a las genuinas, el modelo podría aprender la fuente y no la autenticidad.

La partición por cartera reduce la fuga entre fotografías del mismo producto, pero no resuelve por sí sola todos los atajos. Se requiere revisar metadatos, duplicados y

procedencia; equilibrar, cuando sea posible, las condiciones de captura entre clases; y realizar análisis por segmentos. También es útil inspeccionar mapas de activación para comprobar si el modelo atiende al logo o al cierre en lugar de zonas irrelevantes. Estas visualizaciones no prueban causalidad, pero pueden revelar dependencias sospechosas.

Los resultados preliminares del proyecto muestran degradaciones superiores a cinco puntos porcentuales ante oscuridad y rotación. Este hallazgo coincide con la literatura sobre cambio de dominio y obliga a tratar la robustez como resultado central, no como prueba secundaria. Las perturbaciones finales deben ser plausibles, conservar la etiqueta y aplicarse con parámetros documentados. Además de comparar macro-F1, se debe observar si aumenta la aceptación de falsificaciones, porque una degradación pequeña en la métrica global podría concentrarse en el error de mayor costo.

La aumentación durante el entrenamiento puede mejorar estabilidad, pero debe diseñarse de acuerdo con el dominio. Rotaciones extremas, recortes que eliminan el componente o transformaciones de color irreales pueden alterar la semántica de la muestra. Por ello, el estudio distingue entre aumentaciones de entrenamiento y conjuntos de prueba de robustez: las primeras buscan regularizar; los segundos cuantifican el comportamiento bajo condiciones predefinidas y no deben utilizarse para seleccionar iterativamente el modelo final.

#### ***1.8.9 Evaluación end-to-end, incertidumbre y desempeño operativo***

Gran parte de la literatura reporta el resultado del clasificador sobre imágenes ya recortadas o capturadas bajo instrucciones específicas. Ese diseño permite comparar métodos, pero no representa por completo el flujo de uso. En un sistema end-to-end, una imagen completa pasa por detección, recorte, control de calidad, clasificación, fusión y decisión. Cada etapa puede producir errores, latencia y casos sin evidencia suficiente.

La evaluación por cartera es necesaria porque múltiples imágenes o componentes corresponden al mismo objeto. Contar cada recorte como una muestra independiente puede sobrestimar el tamaño efectivo del test y ocultar contradicciones

entre vistas. La decisión final debe agregarse por `bag_id`, registrar qué componentes estuvieron disponibles y conservar las probabilidades individuales para auditoría.

La incertidumbre puede manejarse mediante un intervalo de rechazo o una categoría no concluyente. El antecedente de Garcia-Cotte et al. [7] muestra que la abstención cambia la relación entre cobertura y exactitud. Para un prototipo académico, conviene informar ambos valores si se implementa rechazo: porcentaje de carteras con decisión y desempeño entre las decididas. No sería correcto reportar solo la mejora de exactitud sin indicar cuántos casos fueron excluidos.

El desempeño operativo tampoco se resume con el promedio de tiempo. La latencia p95 representa mejor la experiencia de la mayoría de solicitudes y permite detectar colas lentas. Debe medirse el pipeline completo, con calentamiento, número de repeticiones, tamaño de lote, hardware y versiones documentadas. Una optimización como `tf.function` puede reducir el tiempo, pero se debe comprobar la equivalencia de las decisiones y aclarar si la medición incluye carga, preprocesamiento y detección.

#### ***1.8.10 Síntesis crítica y brecha de investigación***

El estado del arte muestra avances convergentes: autenticación visual sin modificar el producto; redes de atención para diferencias finas; funciones de pérdida sensibles a falsificaciones difíciles; análisis por partes; detectores para seleccionar evidencia; transferencia de aprendizaje; y esquemas ligeros orientados a despliegue. También revela limitaciones recurrentes: conjuntos privados que dificultan la comparación, protocolos de partición poco detallados, predominio de la exactitud global, evaluación sobre recortes aislados y escasa documentación de robustez y latencia end-to-end.

La investigación propuesta no pretende superar todos los métodos especializados ni generalizar a todas las marcas. Su aporte se ubica en un alcance controlado y verificable: Chanel 2.55 y Boy, componentes logo y *turnlock*, clasificación binaria y comparación de tres backbones. Dentro de ese dominio, la brecha que se aborda es la

evaluación integrada y reproducible del sistema. Se prioriza la separación por cartera física, el test bloqueado, la tasa de aceptación de falsificaciones, el análisis por modelo y componente, la degradación ante iluminación/orientación/contraste y la latencia p95.

La Tabla comparativa resume la relación entre antecedentes y decisiones de la tesis.

Tabla 1. Síntesis de antecedentes y decisiones de la tesis

| Línea de trabajo                            | Aporte observado                                     | Limitación relevante para esta tesis            | Decisión adoptada                                                                   |
|---------------------------------------------|------------------------------------------------------|-------------------------------------------------|-------------------------------------------------------------------------------------|
| Microscopía y aprendizaje automático [1]    | Captura diferencias materiales difíciles de observar | Requiere accesorio especializado                | Usar fotografías convencionales y declarar la pérdida de detalle                    |
| Atención y pérdida guiada por expertos [2]  | Prioriza regiones y falsificaciones difíciles        | Depende de anotación experta y conjunto privado | Medir la clase falsificada y considerar costos asimétricos                          |
| Marco de dos etapas para logos [3]          | Integra información local y global                   | Se concentra en logos y un conjunto reducido    | Detectar logo y turnlock y evaluar el pipeline completo                             |
| Textura con CNN y LBP [5]                   | Combina características aprendidas y textura         | Unidad de análisis centrada en material         | Conservar el análisis por componente y reconocer otros indicios como trabajo futuro |
| Aprendizaje multitarea guiado por áreas [6] | Reduce demanda de muestras y preserva regiones clave | Requiere validar generalización entre series    | Comparar segmentos y condiciones de captura                                         |
| Captura con smartphone y rechazo [7]        | Acerca la autenticación a condiciones reales         | Resultados en prendas no equivalen a carteras   | Evaluar robustez y considerar salida no concluyente                                 |
| Benchmarks de moda [8]-[11]                 | Localización, atributos y representación regional    | No contienen etiquetas de autenticidad          | Transferir principios estructurales, no resultados directos                         |
| Robustez y atajos [17], [18]                | Explican fallos bajo cambio de distribución          | Benchmarks generales, no de carteras            | Diseñar pruebas específicas de oscuridad, rotación y contraste                      |

En síntesis, la literatura respalda la viabilidad técnica de aprender indicios de autenticidad a partir de imágenes, pero no autoriza a interpretar una exactitud alta como certificación universal. La contribución de la tesis consiste en establecer, para el dominio delimitado, cuánto mejora el modelo respecto del baseline, qué errores persisten, cómo varían entre segmentos y condiciones, y si el pipeline satisface el requisito operativo sin ocultar incertidumbre ni dependencia de los datos.

### **1.9 Contribución esperada**

La contribución de la investigación será un procedimiento experimental reproducible para autenticar carteras dentro del alcance definido, integrando:

- localización de componentes visuales;
- clasificación de autenticidad;
- evaluación del error crítico;
- análisis por modelo y componente;
- robustez ante variaciones de captura;
- medición de rendimiento;
- trazabilidad del pipeline.

El resultado esperado no es afirmar que el sistema autentica todas las carteras de lujo, sino determinar con evidencia cuantitativa en qué condiciones funciona, dónde falla y si supera al modelo de referencia dentro del dominio estudiado.

## Capítulo II. Marcos teórico y conceptual

### 2.1 Ejes teóricos

El marco teórico se organiza alrededor de los siguientes ejes:

1. Autenticación visual de productos y falsificaciones.
2. Visión por computadora aplicada a inspección de productos.
3. Redes neuronales convolucionales y transferencia de aprendizaje.
4. Detección de objetos mediante YOLO.
5. Clasificación binaria de imágenes.
6. Análisis por componentes visuales.
7. Desbalance de clases y costos asimétricos de error.
8. Robustez frente a cambios de dominio y condiciones de captura.
9. Reproducibilidad experimental y trazabilidad.
10. Optimización y medición de inferencia.

### 2.2 Definiciones operativas

- **Cartera genuina:** producto etiquetado como auténtico dentro del dataset utilizado.
- **Cartera falsificada:** producto etiquetado como no auténtico dentro del dataset utilizado.
- **Logo:** región visual correspondiente al identificador de marca.
- **Turnlock:** mecanismo de cierre frontal considerado como componente visual.
- **Falsificación aceptada:** muestra falsificada clasificada como genuina.
- **Genuina rechazada:** muestra genuina clasificada como falsificada.
- **Macro-F1:** promedio no ponderado del F1 de ambas clases.
- **Latencia p95:** tiempo máximo dentro del cual finaliza el 95 % de las inferencias medidas.

- **Throughput:** número de imágenes o solicitudes procesadas por unidad de tiempo.
- **Segmento o slice:** subconjunto definido por modelo de cartera, componente o condición de captura.



## Capítulo III. Desarrollo del trabajo de investigación

### 3.1 Tipo y enfoque de investigación

- Investigación tecnológica aplicada.
- Enfoque cuantitativo.
- Diseño experimental comparativo.
- Desarrollo y evaluación de un prototipo.

### 3.2 Unidad de análisis

La unidad principal de análisis será la **cartera física o instancia de producto**. Varias fotografías, recortes o aumentaciones pertenecientes a la misma cartera deberán permanecer en una sola partición para evitar fuga de información.

### 3.3 Datos disponibles

#### 3.3.1 Dataset de detección

Tabla 2. Distribución del dataset de detección

| Partición     | Imágenes | Etiquetas |
|---------------|----------|-----------|
| Entrenamiento | 713      | 713       |
| Validación    | 108      | 108       |
| Total         | 821      | 821       |

Clases de detección:

- logo;
- turnlock.

#### 3.3.2 Dataset de clasificación

Tabla 3. Distribución del dataset de clasificación

| Clase y modelo        | Imágenes |
|-----------------------|----------|
| Genuine — Chanel Boy  | 1 632    |
| Genuine — Chanel 2.55 | 414      |
| Fake — Chanel Boy     | 200      |
| Fake — Chanel 2.55    | 200      |

| Clase y modelo | Imágenes |
|----------------|----------|
| Total          | 2 446    |

El conjunto presenta un desbalance considerable a favor de la clase genuina. Por ello, accuracy y F1 ponderado no serán las únicas métricas principales.

### 3.4 Pipeline de investigación

1. Asignar un identificador único a cada cartera.
2. Registrar imágenes y metadatos de captura.
3. Separar entrenamiento, validación y test por cartera física.
4. Localizar logo y turnlock mediante YOLO.
5. Recortar las regiones detectadas.
6. Aplicar control de calidad a los recortes.
7. Clasificar cada componente como genuino o falsificado.
8. Fusionar las predicciones de los componentes mediante una regla documentada.
9. Emitir una decisión final por cartera.
10. Registrar probabilidad, versión del modelo, latencia, errores y condiciones de entrada.
11. Evaluar resultados globales y por segmento.

### 3.5 Modelos

#### *Detector auxiliar*

- YOLOv8s.
- Resolución de entrada: 640.
- Clases: logo y turnlock.

#### *Clasificadores*

- MobileNetV3: modelo de referencia.
- ResNet50: modelo candidato principal.
- EfficientNetB3: comparación complementaria.

### 3.6 Estrategia de partición

La partición final deberá cumplir:

- separación por `bag_id` o producto físico;
- entrenamiento, validación y test independientes;
- conservación aproximada de las proporciones de clase y modelo;
- test final bloqueado;
- registro de archivos y hashes;
- prohibición de ajustar el umbral usando el test final.

### 3.7 Variables e indicadores

Tabla 4. Variables e indicadores por hipótesis

| Hipótesis | Factor o variable independiente        | Variable dependiente       | Indicadores                                                                                               |
|-----------|----------------------------------------|----------------------------|-----------------------------------------------------------------------------------------------------------|
| H1        | Clasificador: MobileNetV3 vs. ResNet50 | Desempeño de autenticación | Macro-F1, recall de fake, precision de genuine, tasa de aceptación de falsificaciones, accuracy e IC 95 % |
| H2        | Modelo de cartera y componente         | Consistencia del desempeño | Métricas por Chanel 2.55, Chanel Boy, logo y turnlock; brecha máxima y soporte                            |
| H3        | Condición de captura                   | Robustez                   | Variación de macro-F1, recall de fake y tasa de aceptación de falsificaciones                             |
| H4        | Inferencia original vs. optimizada     | Rendimiento operativo      | p50, p95, throughput, coincidencia de predicciones y hardware                                             |

#### ***Variables de control***

- semilla aleatoria;
- resolución de entrada;
- preprocesamiento;
- umbral de clasificación;
- versiones de librerías;
- hardware;
- versión del dataset;

- partición de datos;
- pesos del modelo;
- regla de fusión.

### **3.8 Métricas principales**

1. Macro-F1.
2. Recall de la clase falsificada.
3. Precision de la predicción genuina.
4. Tasa de aceptación de falsificaciones.
5. Tasa de rechazo de genuinas.
6. Matriz de confusión.
7. Intervalos de confianza.
8. Latencia p50 y p95.
9. Throughput.
10. Métricas por segmento.

### **3.9 Experimentos**

#### ***Experimento 1. Comparación de clasificadores***

Comparar MobileNetV3, ResNet50 y EfficientNetB3 sobre la misma partición final.

La comparación principal será ResNet50 frente a MobileNetV3.

#### ***Experimento 2. Evaluación por segmentos***

Calcular métricas separadas para:

- Chanel 2.55;
- Chanel Boy;
- logo;
- turnlock.

### **Experimento 3. Robustez**

Evaluar imágenes originales y variantes representativas de:

- iluminación insuficiente;
- rotación moderada;
- bajo contraste.

Las perturbaciones deberán conservar la etiqueta y representar condiciones plausibles de captura.

### **Experimento 4. Rendimiento operativo**

Comparar la inferencia original y la optimizada mediante:

- coincidencia de predicciones;
- p50;
- p95;
- throughput;
- consumo de memoria;
- hardware documentado.

### **Experimento 5. Evaluación end-to-end**

Procesar imágenes completas no utilizadas en el desarrollo:

imagen completa → detección → recorte → clasificación → fusión → decisión final.

La unidad de resultado será la cartera, no el recorte aislado.

## **3.10 Criterios de aceptación**

Tabla 5. Criterios de aceptación experimental

| Criterio                        | Regla                                                                                                                                     |
|---------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|
| Superioridad frente al baseline | Macro-F1 mayor y tasa de aceptación de falsificaciones menor; la diferencia deberá analizarse con intervalo de confianza y prueba pareada |
| Consistencia por segmento       | Brecha no mayor de 5 puntos porcentuales                                                                                                  |
| Robustez                        | Degradación no mayor de 5 puntos porcentuales                                                                                             |

| Criterio                     | Regla                                                                            |
|------------------------------|----------------------------------------------------------------------------------|
| Latencia end-to-end          | p95 menor o igual a 2 segundos                                                   |
| Equivalencia de optimización | Misma decisión de clase y diferencias numéricas dentro de la tolerancia definida |
| Tamaño de segmento           | No extraer conclusiones firmes de segmentos sin tamaño suficiente                |

### 3.11 Pruebas estadísticas

- Bootstrap pareado para intervalos de confianza de las diferencias.
- Prueba de McNemar para comparar errores de dos clasificadores sobre las mismas muestras.
- Intervalos de confianza para tasas de error.
- Reporte del tamaño de cada segmento.
- No utilizar el test final para selección de modelo o umbral.

### 3.12 Reproducibilidad

El repositorio deberá incluir:

```
data/
  raw/
  processed/
  splits/
models/
notebooks/
src/
logs/
reports/
requirements.txt
README.md
```

También deberá registrar:

- versiones exactas de Python y librerías;
- semillas;
- pesos de modelos;
- hashes del dataset;
- hardware;
- orden de ejecución;
- fecha y hora de los experimentos;

- métricas consolidadas;
- configuración del umbral;
- lista exacta de muestras de cada partición.

## Capítulo IV. Análisis y discusión de resultados

### 4.1 Resultados preliminares de clasificación

Tabla 6. Resultados preliminares de clasificación

| Modelo         | Mejor accuracy de validación observada |
|----------------|----------------------------------------|
| EfficientNetB3 | 0.9018                                 |
| MobileNetV3    | 0.9284                                 |
| ResNet50       | 0.9387                                 |

ResNet50 presentó el mayor resultado observado en la partición utilizada. Esta evidencia es preliminar y deberá confirmarse sobre un test independiente.

### 4.2 Resultados preliminares por clase de ResNet50

Tabla 7. Resultados preliminares por clase de ResNet50

| Clase          | Precision | Recall | F1   | Soporte |
|----------------|-----------|--------|------|---------|
| Fake           | 0.78      | 0.87   | 0.82 | 83      |
| Genuine        | 0.97      | 0.95   | 0.96 | 406     |
| Macro promedio | 0.88      | 0.91   | 0.89 | 489     |

La matriz de confusión reportada equivale aproximadamente a:

- 72 falsificaciones detectadas correctamente;
- 11 falsificaciones aceptadas como genuinas;
- 386 genuinas reconocidas correctamente;
- 20 genuinas rechazadas.

Tasas aproximadas:

- aceptación de falsificaciones: **13.3 %**;
- rechazo de genuinas: **4.9 %**.

### 4.3 Resultados preliminares de detección

Tabla 8. Resultados preliminares de detección

| Clase    | Precision | Recall | mAP50 | mAP50-95 |
|----------|-----------|--------|-------|----------|
| Todas    | 0.954     | 0.833  | 0.888 | 0.659    |
| Logo     | 0.909     | 0.786  | 0.827 | 0.563    |
| Turnlock | 1.000     | 0.881  | 0.949 | 0.755    |



El turnlock presenta mejores resultados que el logo. El menor recall del logo puede limitar el pipeline completo.

#### 4.4 Resultados preliminares de robustez

Tabla 9. Resultados preliminares de robustez

| Condición      | Accuracy | F1 reportado | Variación de accuracy |
|----------------|----------|--------------|-----------------------|
| Original       | 0.9366   | 0.9614       | 0.00 pp               |
| Oscura         | 0.8487   | 0.9019       | -8.79 pp              |
| Rotada         | 0.8671   | 0.9155       | -6.95 pp              |
| Contraste bajo | 0.8998   | 0.9379       | -3.68 pp              |

Los resultados preliminares indican que oscuridad y rotación superan el margen de degradación de cinco puntos porcentuales. La hipótesis de robustez podría rechazarse si el test final confirma este comportamiento.

#### 4.5 Resultados preliminares de rendimiento

Tabla 10. Resultados preliminares de rendimiento

| Configuración            | p50       | p95       | Solicitudes/s |
|--------------------------|-----------|-----------|---------------|
| MobileNetV3 baseline     | 175.23 ms | 179.58 ms | 5.69          |
| ResNet50 original        | 223.75 ms | 230.01 ms | 4.46          |
| ResNet50 con tf.function | 7.36 ms   | 8.45 ms   | 124.24        |

Estos valores corresponden a la sesión experimental registrada. Deberán repetirse indicando hardware, versiones, calentamiento, número de repeticiones y condiciones de ejecución.

#### 4.6 Validación pendiente antes de las conclusiones

1. Crear la partición por cartera física.
2. Reservar un test independiente.
3. Integrar detector, recorte, clasificador y regla de fusión.
4. Evaluar la decisión final por cartera.
5. Calcular métricas por modelo y componente.
6. Estimar intervalos de confianza.

7. Comparar ResNet50 y MobileNetV3 con pruebas pareadas.
8. Repetir el benchmark en un entorno documentado.
9. Verificar el costo del error de aceptar una falsificación.
10. Reportar limitaciones sin generalizar fuera del alcance.

## Conclusiones

Las conclusiones que siguen tienen carácter preliminar, porque todavía debe completarse la evaluación sobre un test independiente separado por cartera física y ejecutarse el pipeline end-to-end. No constituyen una certificación comercial ni una generalización a otras marcas o modelos.

1. ResNet50 presenta el mayor resultado preliminar de validación entre las arquitecturas comparadas. Sin embargo, la superioridad frente a MobileNetV3 debe confirmarse sobre las mismas carteras de prueba, mediante macro-F1, tasa de aceptación de falsificaciones, intervalos de confianza y una comparación pareada.
2. El desempeño por clase muestra una asimetría relevante. La clase falsificada obtiene resultados inferiores a la clase genuina y la tasa preliminar de falsificaciones aceptadas es aproximadamente 13,3 %. Por tanto, la exactitud global no es suficiente para caracterizar la utilidad del sistema.
3. El detector localiza el *turnlock* con mejor desempeño que el logo. El menor *recall* del logo puede limitar la disponibilidad de evidencia y debe analizarse dentro del pipeline completo, no únicamente como métrica aislada de detección.
4. Las pruebas preliminares de oscuridad y rotación producen degradaciones mayores al margen de cinco puntos porcentuales establecido. La hipótesis de robustez podría rechazarse si este comportamiento se mantiene en el test final.
5. La optimización mediante `tf.function` muestra una reducción sustancial del tiempo de inferencia registrado. El resultado debe repetirse bajo un protocolo documentado e incluir detección, preprocesamiento, clasificación, fusión y decisión por cartera.
6. La principal contribución esperada no es afirmar autenticidad universal, sino establecer un procedimiento reproducible que permita conocer el desempeño, los

errores, los segmentos vulnerables y las condiciones operativas dentro del dominio definido.

## Recomendaciones

1. Construir y bloquear una partición final por `bag_id`, verificando duplicados, procedencia y equilibrio aproximado de clases y modelos antes de comparar arquitecturas.
2. Incrementar la cantidad y diversidad de falsificaciones verificadas, en especial imitaciones de alta calidad y fotografías tomadas con dispositivos y fondos semejantes a los de la clase genuina.
3. Incorporar un control automático de calidad de imagen y considerar una salida “no concluyente” cuando falte un componente, el recorte sea insuficiente o la confianza esté fuera del intervalo validado.
4. Evaluar reglas de fusión de logo y *turnlock* exclusivamente con el conjunto de validación y reportar la decisión final por cartera junto con la disponibilidad de cada componente.
5. Reentrenar con aumentaciones plausibles de iluminación, orientación y contraste, manteniendo un conjunto de robustez independiente para evitar ajustar el modelo directamente a las pruebas.
6. Ampliar trabajos futuros a costuras, etiquetas, códigos, texturas y otras marcas o modelos, sin mezclar esos alcances con las conclusiones del experimento actual.
7. Documentar hardware, versiones, semillas, pesos, hashes, umbrales y tiempos p50/p95 para que los resultados puedan reproducirse y auditarse.

## Referencias bibliográficas

- [1] A. Sharma, V. Srinivasan, V. Kanchan y L. Subramanian, "The Fake vs Real Goods Problem: Microscopy and Machine Learning to the Rescue," en *Proc. 23rd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2017, pp. 2011-2019, doi: 10.1145/3097983.3098186.
- [2] J. Peng, B. Zou, X. He y C. Zhu, "Hybrid attention network with appraiser-guided loss for counterfeit luxury handbag detection," *Complex & Intelligent Systems*, vol. 8, pp. 2371-2381, 2022, doi: 10.1007/s40747-021-00633-1.
- [3] J. Peng, B. Zou y C. Zhu, "A two-stage deep learning framework for counterfeit luxury handbag detection in logo images," *Signal, Image and Video Processing*, vol. 17, no. 4, pp. 1439-1448, 2023, doi: 10.1007/s11760-022-02352-7.
- [4] J. Peng, B. Zou y C. Zhu, "Combining external attention GAN with deep convolutional neural networks for real-fake identification of luxury handbags," *The Visual Computer*, vol. 39, no. 3, pp. 971-982, 2023, doi: 10.1007/s00371-021-02378-x.
- [5] P. Apipawinwongsa y Y. Limpiyakorn, "Counterfeit Luxury Handbag Materials Image Classification using Deep Learning and Local Binary Pattern," *International Journal of Emerging Technology and Advanced Engineering*, vol. 12, no. 9, pp. 41-48, 2022, doi: 10.46338/ijetae0922\_05.
- [6] Y. Yang, Y. Yang, L. Zhou y J. Zou, "A lightweight multi-task learning network based on key area guidance for counterfeit detection," *Signal, Image and Video Processing*, vol. 18, pp. 4675-4685, 2024, doi: 10.1007/s11760-024-03105-4.
- [7] H. Garcia-Cotte, D. Mellouli, A. Rehman, L. Wang y D. G. Stork, "Deep neural network-based detection of counterfeit products from smartphone images," *arXiv preprint arXiv:2410.05969*, 2024, doi: 10.48550/arXiv.2410.05969.
- [8] Z. Liu, P. Luo, S. Qiu, X. Wang y X. Tang, "DeepFashion: Powering Robust Clothes Recognition and Retrieval with Rich Annotations," en *Proc. IEEE Conf. Computer Vision and Pattern Recognition*, 2016, pp. 1096-1104.

- [9] Y. Ge, R. Zhang, X. Wang, X. Tang y P. Luo, "DeepFashion2: A Versatile Benchmark for Detection, Pose Estimation, Segmentation and Re-Identification of Clothing Images," en *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2019, pp. 5337-5345.
- [10] M. Jia et al., "Fashionpedia: Ontology, Segmentation, and an Attribute Localization Dataset," en *Proc. European Conf. Computer Vision*, 2020.
- [11] Y. Lang, Y. He, F. Yang, J. Dong y H. Xue, "Which Is Plagiarism: Fashion Image Retrieval Based on Regional Representation for Design Protection," en *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2020, pp. 2595-2604.
- [12] K. He, X. Zhang, S. Ren y J. Sun, "Deep Residual Learning for Image Recognition," en *Proc. IEEE Conf. Computer Vision and Pattern Recognition*, 2016, pp. 770-778.
- [13] M. Tan y Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," en *Proc. 36th Int. Conf. Machine Learning*, vol. 97, 2019, pp. 6105-6114.
- [14] A. Howard et al., "Searching for MobileNetV3," en *Proc. IEEE/CVF Int. Conf. Computer Vision*, 2019, pp. 1314-1324.
- [15] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," en *Proc. IEEE Conf. Computer Vision and Pattern Recognition*, 2016, pp. 779-788.
- [16] Y. Cui, M. Jia, T.-Y. Lin, Y. Song y S. Belongie, "Class-Balanced Loss Based on Effective Number of Samples," en *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition*, 2019, pp. 9268-9277.
- [17] D. Hendrycks y T. Dietterich, "Benchmarking Neural Network Robustness to Common Corruptions and Perturbations," en *Proc. Int. Conf. Learning Representations*, 2019.
- [18] R. Geirhos et al., "Shortcut learning in deep neural networks," *Nature Machine Intelligence*, vol. 2, no. 11, pp. 665-673, 2020, doi: 10.1038/s42256-020-00257-z.

- [19] C. Guo, G. Pleiss, Y. Sun y K. Q. Weinberger, “On Calibration of Modern Neural Networks,” en *Proc. 34th Int. Conf. Machine Learning*, 2017, pp. 1321-1330.